



Annonces

Déclaration concernant la directive du gouvernement américain suspendant l'accès à Fable 5 et Mythos 5

12 juin 2026

Le gouvernement américain, invoquant des raisons de sécurité nationale, a émis une directive de contrôle des exportations suspendant tout accès à Fable 5 et Mythos 5 pour toute personne de nationalité étrangère, qu'elle se trouve aux États-Unis ou à l'étranger, y compris les employés étrangers d'Anthropic. De ce fait, nous devons désactiver immédiatement Fable 5 et Mythos 5 pour **tous** nos clients afin de nous conformer à cette directive. **L'accès à tous les autres modèles d'Anthropic reste inchangé.**

Nous avons reçu aujourd'hui à 17h21 (heure de l'Est) la directive du gouvernement. La lettre ne précisait pas la nature de ses préoccupations en matière de sécurité nationale. Il semblerait que le gouvernement ait découvert une méthode permettant de contourner, ou de « jailbreaker », Fable 5. Nous avons examiné une démonstration de cette technique, utilisée pour identifier un petit nombre de vulnérabilités mineures déjà connues. Ces vulnérabilités paraissent relativement simples, et nous avons constaté que d'autres modèles disponibles publiquement sont également capables de les détecter sans nécessiter de contournement.

La position d'Anthropic concernant les mesures de protection de Fable, telle que présentée dans notre [article de blog de lancement](#), est la suivante :

- Nous avons mis en place des mesures de sécurité rigoureuses qui réduisent considérablement le risque d'utilisation abusive de Fable à des fins liées à la cybersécurité (entre autres). Ces mesures sont si strictes que de nombreux utilisateurs les jugent excessivement larges.
- Dans les semaines précédant le lancement de Fable, Anthropic a travaillé avec le gouvernement américain, l'AIISI britannique, de multiples organisations tierces

privées et des équipes internes pour tester les mesures de sécurité de Fable pendant des milliers d'heures au total.

- Ces tests ont démontré que les mécanismes de protection de Fable sont nettement plus efficaces que ceux de tous les modèles déployés précédemment.
- Aucun testeur n'a encore réussi à trouver un *jailbreak universel* — une méthode de jailbreak capable de contourner très largement les protections du modèle, débloquent ainsi un large éventail de capacités cybernétiques.
- Nous pensons qu'une résistance parfaite au jailbreak est actuellement impossible pour tous les fabricants de modèles. Chaque système de sécurité utilisé dans le secteur est vulnérable aux *jailbreaks non universels* (qui peuvent permettre d'obtenir *certaines* informations informatiques dans des circonstances spécifiques), et il est probable que des jailbreaks universels soient découverts à l'avenir. Nous l'avons clairement indiqué lors de la sortie de Fable 5.
- Étant donné qu'une résistance parfaite au jailbreak semble impossible à ce jour, Anthropic a adopté une stratégie *de défense en profondeur* avec Fable 5. Notre objectif était de rendre les jailbreaks soit limités (dans le cas des jailbreaks non universels), soit très coûteux à produire (dans le cas des jailbreaks universels), et de combiner cela avec une surveillance rigoureuse afin de détecter et de neutraliser rapidement toute attaque réussie. C'est également pourquoi Anthropic exige la conservation des données clients pendant 30 jours avec Fable — un changement de politique qui engendre des coûts réels pour nos clients, mais qui nous permet de mener des recherches et de contrer les jailbreaks.
- Nous maintenons notre soutien à cette stratégie de défense en profondeur. Elle réduit les risques liés à Fable, les rendant comparables à ceux des modèles existants déjà déployés dans l'industrie.
- Nous n'avons même pas reçu de signalement concernant une faille de sécurité potentielle, non universelle et préoccupante, ayant entraîné des conséquences néfastes. Les failles potentielles qui nous ont été signalées sont soit des réactions totalement bénignes, soit des découvertes mineures n'apportant aucun avantage spécifique à Mythos.

À ce jour, le gouvernement ne nous a fourni que des preuves verbales concernant une possible faille de sécurité limitée et non universelle, consistant essentiellement à demander au modèle d'analyser un code source spécifique et de corriger les failles logicielles. Nous avons cru comprendre qu'une faille potentielle avait été communiquée au gouvernement. Nous avons examiné un rapport qui, selon nous, est à l'origine de la directive gouvernementale et avons vérifié que le niveau de capacité présenté est largement accessible à d'autres modèles (notamment GPT-5.5 d'OpenAI) et est utilisé quotidiennement par les équipes de

sécurité. Nous communiquerons davantage d'informations dans les prochaines 24 heures.

Nous nous conformons à la directive gouvernementale et supprimons l'accès à Fable 5 et Mythos 5 pour tous les utilisateurs. Cependant, nous contestons que la découverte d'une faille de sécurité potentielle, même minime, justifie le retrait d'un modèle commercial déployé auprès de centaines de millions de personnes. Si cette norme était appliquée à l'ensemble du secteur, nous pensons qu'elle bloquerait de facto tout nouveau déploiement de modèle pour tous les fournisseurs de modèles innovants.

Comme nous l'avons déclaré publiquement, nous estimons que le gouvernement devrait avoir la possibilité de bloquer les déploiements dangereux, dans le cadre d'une procédure légale transparente, équitable, claire et fondée sur des faits techniques. Cette action ne respecte pas ces principes.

Nous nous excusons pour la gêne occasionnée. Nous pensons qu'il s'agit d'un malentendu et nous mettons tout en œuvre pour rétablir l'accès au plus vite.



Contenu associé

Résultats du premier registre public anthropique

En savoir plus →

TCS et Anthropic s'associent pour déployer Claude dans les secteurs réglementés.

Nous annonçons un partenariat avec Tata Consultancy Services (TCS). TCS déploiera Claude auprès de 50 000 de ses collaborateurs répartis dans 56 pays ; développera des produits basés sur Claude pour ses clients des secteurs de la finance, de la santé, du secteur public et d'autres industries réglementées ; et rejoindra le réseau de partenaires Claude.

En savoir plus →

DXC intégrera Claude aux systèmes sur lesquels s'appuient les banques, les compagnies aériennes et d'autres secteurs réglementés.

Nous annonçons une alliance mondiale pluriannuelle avec DXC Technology, l'une des plus grandes sociétés de services informatiques au monde.

En savoir plus →



Produits

Claude

Code Claude

Claude Code Enterprise

Claude Cowork

Claude Security

Claude pour Chrome

Claude pour Slack

Claude pour Microsoft 365

Compétences

Télécharger l'application

Tarification

Connectez-vous à Claude

Modèles

Mythe

Fable

Opus

Sonnet

Haïku

Solutions

agents IA

Modernisation du code

Codage

Service client

Éducation

Entreprise

services financiers

Gouvernement

Soins de santé

Légal

sciences de la vie

organisations à but non lucratif

Sécurité

petite entreprise

Start-ups

Plateforme Claude

Aperçu

Documentation pour les développeurs

Tarification

Marché

Conformité régionale

Claude sur AWS

Vertex AI de Google Cloud

Microsoft Foundry

Connexion à la console

Ressources

Blog

Réseau de partenaires Claude

Communauté

Connecteurs

Cours

Témoignages clients

Ingénierie chez Anthropic

Événements

Code intérieur de Claude

À l'intérieur de Claude Cowork

À l'intérieur de Claude Enterprise

Sécurité interne de Claude

Plugins

Propulsé par Claude

Partenaires de service

Tutoriels

Cas d'utilisation

Aide et sécurité

Disponibilité

Statut

Centre d'assistance

Entreprise

Anthropique

Carrières

Politique

Avenir économique

Recherche

Nouvelles

La Constitution de Claude

Claude Corps

Politique relative à l'exponentielle de l'IA

Politique de mise à l'échelle responsable

Sécurité et conformité

Transparence

Conditions générales et politiques

choix de confidentialité

Politique de confidentialité

politique de confidentialité des données de santé des consommateurs

Politique de divulgation responsable

Conditions générales d'utilisation : Commerciales

Conditions générales d'utilisation : Consommateur

politique d'utilisation

© 2026 Anthropic PBC

